Evaluación Sistemática de la Precisión Estructural de AlphaFold2

Validación PDB–AlphaFold2 con mapeo SIFTS, RMSD estratificado e inferencia bayesiana

José Antonio Tapia Godínez[1] **Dr. Edgar Francisco Román Rangel**[1] (Asesor)

[1]ITAM, Maestría en Ciencia de Datos — jose.tapia@itam.mx

1. Motivación y control SIFTS

AlphaFold2 (DeepMind, 2021) predice la estructura 3D de proteínas a partir de su secuencia de aminoácidos (GDT 92,4/100 en CASP14).

Pregunta: ¿cuándo puede usarse una predicción de AlphaFold2 como sustituto estructural confiable?

- Validación a gran escala contra estructuras PDB.
- Comparación por longitud, aminoácido, grupo funcional y elemento.
- Base reproducible para comparar con modelos posteriores.

SIFTS (*Structure Integration with Function, Taxonomy and Sequence*): mapea residuos PDB a UniProt, corrigiendo cadena y numeración.

Control crítico: sin SIFTS, el RMSD se infla **35**×.

Métrica	Sin SIFTS	Con SIFTS
RMSD mediana	22,54 Å	**0,64 Å**
< 2 Å	13,9 %	**87,7 %**
> 10 Å	80,9 %	**0,4 %**

2. Conjunto de datos

10.432 proteínas únicas (1 PDB por UniProt ID), del archivo SIFTS (68.591 IDs disponibles).

Etapa	N
Pares candidatos (SIFTS)	13.000
Ambos archivos descargados	11.384
Procesados exitosamente	**10.432**
Tasa de éxito	91,6 %

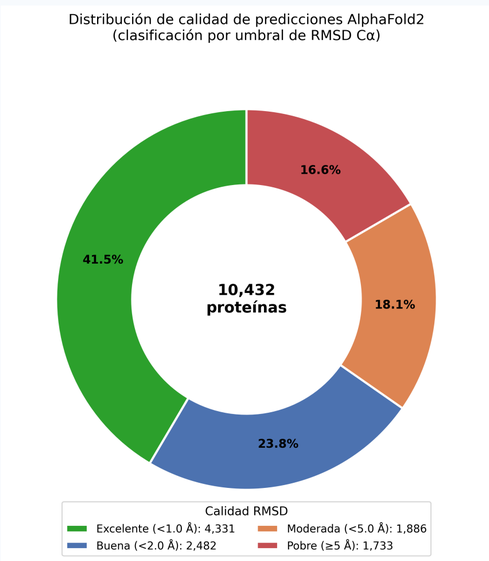

65,3 % con RMSD < 2 Å (Buena + Excelente)

3. *Pipeline* de evaluación

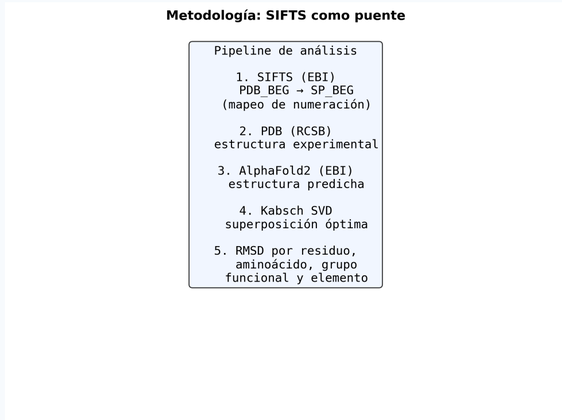

1. **Mapeo SIFTS:** PDB → UniProt → AlphaFold.
2. **Superposición:** Kabsch (SVD) sobre átomos *backbone*.
3. **Estratificación:** longitud → aminoácido → grupo → elemento.

Métrica principal

$$\mathrm{RMSD} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left\|\mathbf{r}_i^{\mathrm{exp}} - \mathbf{r}_i^{\mathrm{pred}}\right\|^2}$$

< 1 Å excelente | < 2 Å buena | < 5 Å moderada | ≥ 5 Å pobre

4. Resultados globales y longitud

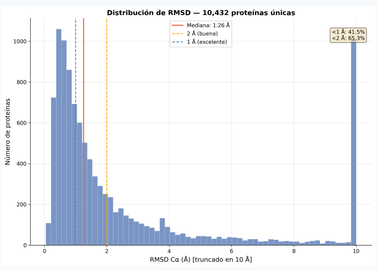

Distribución global RMSD (10.432 prot.)

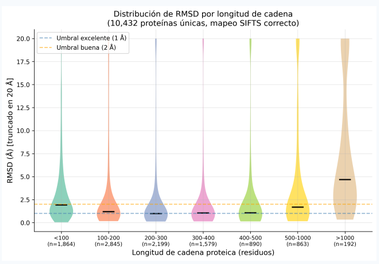

RMSD por categoría de longitud

Categoría	N	Media	Med.	<1 Å	<2 Å
<100	1.908	3,52	1,91	26,9 %	52,0 %
100–200	2.819	3,42	1,20	43,1 %	66,9 %
200–300	**2.194**	**2,88**	**0,98**	**51,1 %**	**74,0 %**
300–500	2.463	3,00	1,06	47,6 %	73,0 %
500–1000	857	5,97	1,69	34,8 %	55,0 %
>1000	191	10,59	4,68	5,2 %	22,5 %
Global	**10.432**	**3,56**	**1,26**	**41,5 %**	**65,3 %**

No existe "*sweet spot*": precisión alta para 100–500 res. El óptimo aparente en 250–300 era un **artefacto del desfase de numeración**.

Interpretación estadística

- La **mediana** describe mejor el desempeño típico que la media, porque la distribución de RMSD tiene cola derecha.
- El umbral **< 2 Å** separa modelos adecuados para uso estructural exploratorio de casos que requieren revisión.
- Proteínas muy largas acumulan incertidumbre por dominios múltiples, flexibilidad y diferencias de estado conformacional.
- Los *outliers* no son solo ruido: pueden indicar complejos, ligandos, dominios ausentes o cambios apo–holo.

5. Jerarquía química de precisión

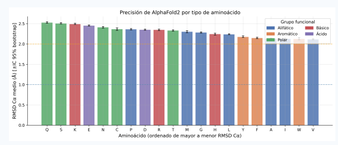

Nivel 2: RMSD por aminoácido (2,86M res.)

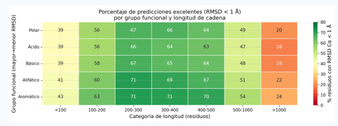

Nivel 3: % excelente grupo funcional × longitud

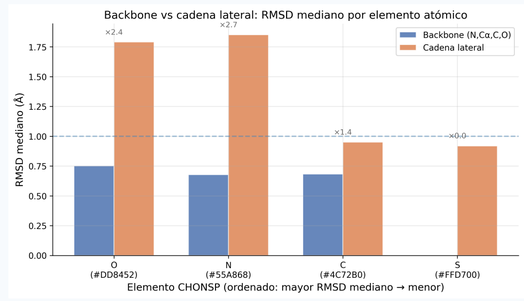

Nivel 4: *Backbone* vs cadena lateral

Gradiente de precisión

- **Mejor:** alifáticos del núcleo (V, I, L)
- **Peor:** cargados de superficie (K, R, E)
- *Backbone* siempre más preciso (×1,1–1,4)
- **C** > **N**, **O**; **S** variable

6. Inferencia bayesiana

Modelo **Beta-Binomial**, prior Beta(1, 1), para $P(\mathrm{RMSD} < 1\,\text{Å})$:

$$p \mid k, n \;\sim\; \mathrm{Beta}(1+k,\; 1+n-k)$$

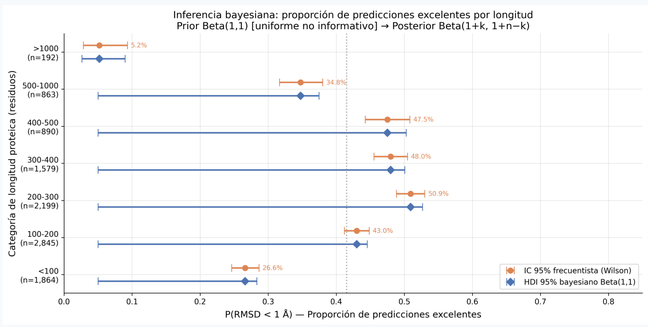

HDI 95 % bayesiano vs IC Wilson 95 %.

Para n grandes ambos convergen; en proteínas >1.000 res. la incertidumbre posterior aumenta por menor muestra.

Implicaciones biológicas

- Las regiones de **núcleo hidrofóbico** muestran mayor estabilidad geométrica y menor dispersión de RMSD.
- Residuos cargados de superficie concentran mayor error por movilidad, solvente y dependencia del entorno experimental.
- El *backbone* es consistentemente más confiable que cadenas laterales para análisis comparativos de gran escala.

7. Conclusiones científicas y recomendaciones

Lectura principal

- El mapeo SIFTS es obligatorio para comparaciones PDB–AlphaFold.
- La precisión alta se concentra en 100–500 residuos.
- No hay "*sweet spot*" real: era un artefacto de numeración.

Uso recomendado

✓ *Docking* exploratorio y diseño de mutantes.
✓ Mayor confianza en núcleo hidrofóbico.
△ Precaución con estados *holo*.

Siguiente etapa

- Evaluar AlphaFold3 bajo el mismo protocolo.
- Separar errores por dominio CATH/SCOP.
- Comparar con RoseTTAFold y ESMFold.