Precisión estructural real de AlphaFold2 tras corregir el mapeo PDB–UniProt

Benchmark sistemático con SIFTS sobre 10,432 proteínas únicas | reducción de 35× en el error mediano aparente

José Antonio Tapia Godínez | Maestría en Ciencia de Datos, ITAM | jose.tapia@itam.mx
Asesor: Dr. Edgar Francisco Román Rangel | Concurso de Posters de Titulación 2026

AlphaFold2
Benchmark estructural · SIFTS

Estructura proteica predicha por AlphaFold2 · AlphaFold DB

10,432 proteínas únicas procesadas con SIFTS	**1.26 Å** RMSD mediano dataset diversificado	**65.3 %** predicciones < 2 Å nivel útil para bioinformática	**35×** reducción de error al usar mapeo SIFTS

Hallazgo clave. Sin mapeo SIFTS, el benchmark exagera el error de AlphaFold2. Al corregir la correspondencia PDB–UniProt, el RMSD mediano cae de **22.54 Å** a **0.64 Å** en el subset validado, con un desempeño global de **1.26 Å**.

Problema, datos y método

Problema. Comparar PDB y AlphaFold2 por número de residuo, sin corregir cadena ni numeración, infla artificialmente el error estructural.
Objetivo. Cuantificar la precisión estructural real de AlphaFold2 con un pipeline reproducible basado en SIFTS y alineamiento Kabsch.
Diseño del estudio.

- RCSB PDB + AlphaFold DB + SIFTS como fuentes principales.
- Un PDB representativo por identificador UniProt.
- 13,000 pares candidatos → 11,384 descargados → **10,432 procesados** con éxito.
- Subset validado de **5,115 pares** con inicio de mapeo explícito.

Variables principales.

- Respuesta: RMSD de Cα tras alineamiento Kabsch.
- Estructurales y químicas: longitud proteica, residuos mapeados, aminoácido y tipo de átomo.

Justificación metodológica. SIFTS resuelve los dos errores más comunes en benchmarks PDB–AF2: desfase de numeración y selección incorrecta de cadena. Kabsch es la solución rígida óptima para superposición.

Pipeline Analítico

Metodología: SIFTS como puente

```
Pipeline de análisis

1. SIFTS (EBI)
PDB_BEG → SP_BEG
(mapeo de numeración)

2. PDB (RCSB)
estructura experimental

3. AlphaFold2 (EBI)
estructura predicha

4. Kabsch SVD
superposición óptima

5. RMSD por residuo,
aminoácido, grupo
funcional y elemento
```

Flujo de trabajo. Descarga → mapeo SIFTS → extracción de residuos comunes → superposición Kabsch → cálculo de RMSD → análisis estructural.
Implementación. Python 3, Biopython, NumPy, Pandas y Matplotlib/Seaborn.

El Cambio que Introduce SIFTS

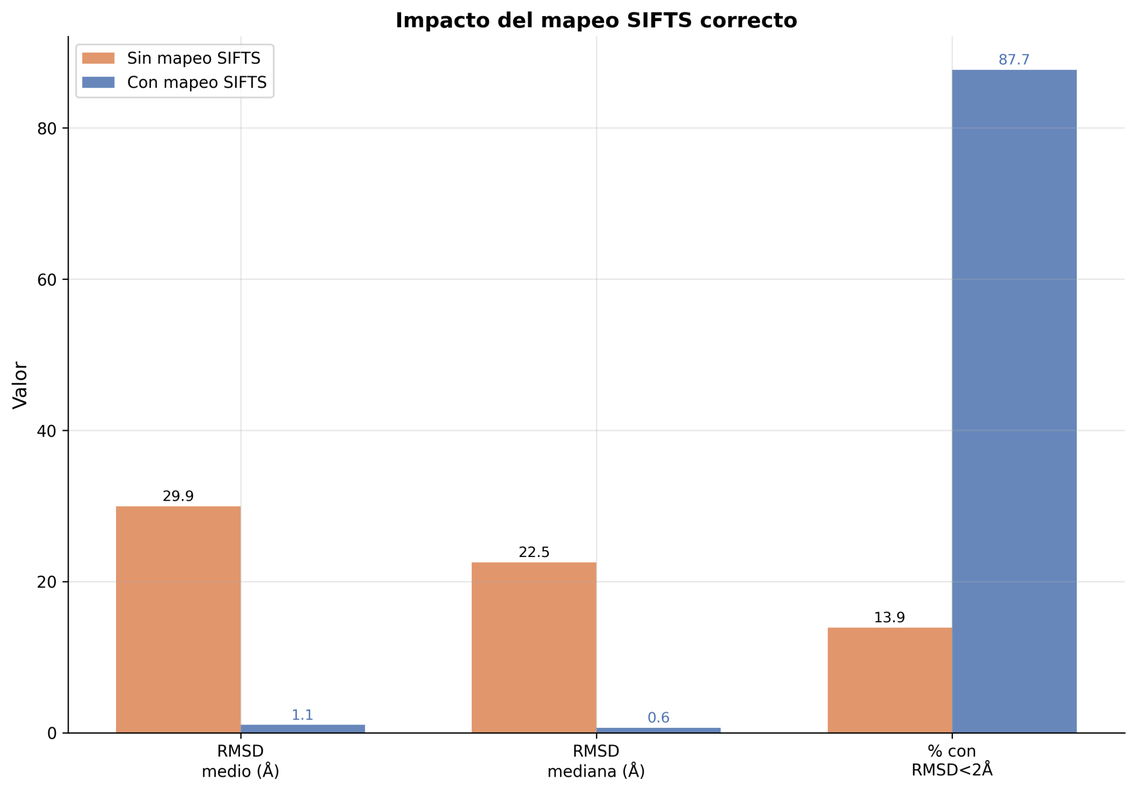

29.94 Å → 1.05 Å RMSD medio	**22.54 Å → 0.64 Å** RMSD mediano
13.9 % → 87.7 % Predicciones con RMSD < 2 Å	**80.9 % → 0.4 %** Predicciones con RMSD > 10 Å

Lectura. La mayor parte del error reportado por benchmarks ingenuos no provenía de AlphaFold2, sino de comparar residuos incorrectos. SIFTS cambia la interpretación completa del problema.

Desempeño Global

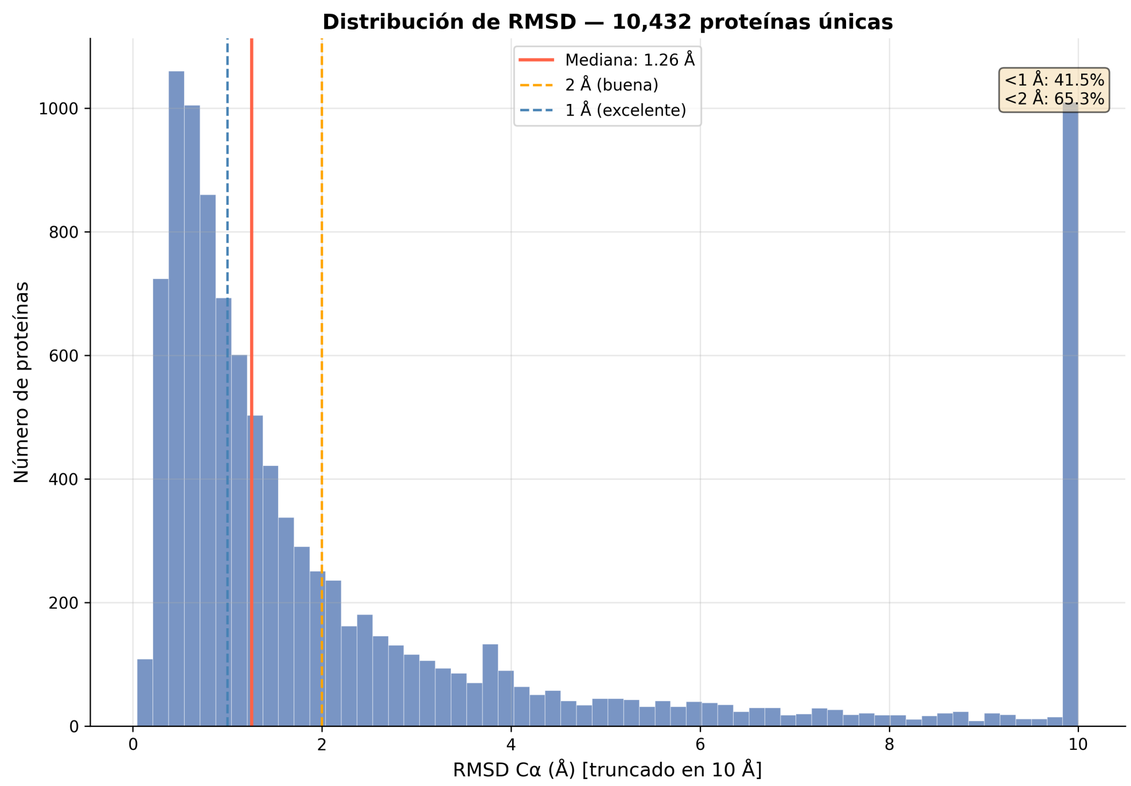

- **10,432 proteínas únicas** en el dataset diversificado final.
- **RMSD mediano: 1.26 Å**. RMSD medio: 3.56 Å.
- **41.5 %** con RMSD < 1 Å y **65.3 %** con RMSD < 2 Å.
- La distribución tiene cola derecha; la mediana describe mejor el comportamiento típico.

Lectura. Para una fracción amplia del proteoma, AlphaFold2 alcanza precisión estructural en el rango útil para bioinformática estructural y modelado molecular.

Efecto del Tamaño Proteico

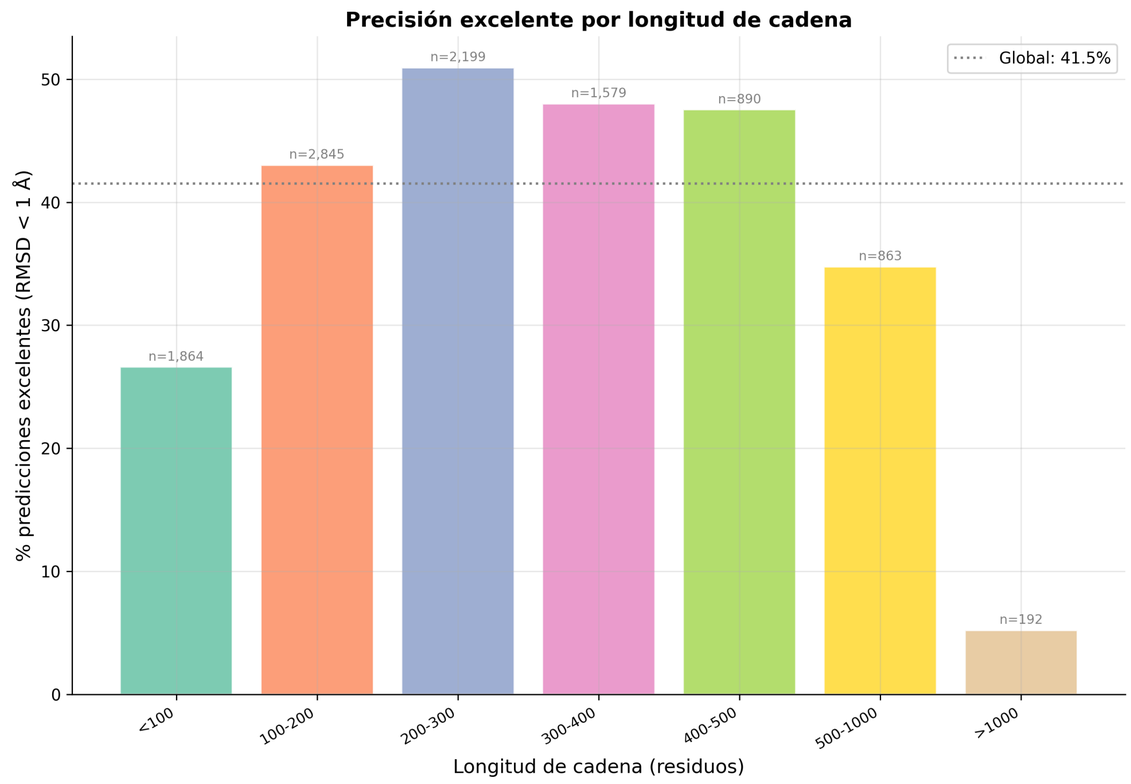

- No aparece un *sweet spot* universal y rígido de 250–300 residuos.
- Los rangos **200–300** y **300–400** mantienen métricas especialmente fuertes.
- El deterioro importante se concentra en proteínas muy grandes, por arriba de **1000 residuos**.

Ejemplos cuantitativos.

- 200–300 residuos: mediana 0.98 Å y 51.1 % excelentes.
- 300–400 residuos: mediana 1.05 Å y 47.9 % excelentes.
- > 1000 residuos: mediana 4.68 Å y 5.2 % excelentes.

Conclusiones e Impacto

- **AlphaFold2 alcanza alta precisión estructural** en el dataset analizado: RMSD mediano global de 1.26 Å.
- **SIFTS no es opcional**: es un requisito metodológico para comparar PDB y AlphaFold de forma válida.
- El supuesto *sweet spot* 250–300 era sobre todo un artefacto del desfase de numeración.
- Los outliers se explican por conformaciones apo/holo, dominios móviles, desorden intrínseco o mapeos incompletos.
- El pipeline es **reproducible y transferible** a AlphaFold3 y otros predictores estructurales.

Aplicaciones prácticas.

- *Docking* molecular y *virtual screening*
- Diseño racional, modelado por homología y anotación funcional

Reproducibilidad. Código y reporte: github.com/AntonioIQ/alphafold-project | **Compilación:** make poster | **Datos:** RCSB PDB, AlphaFold DB y SIFTS | **Citas clave:** Jumper et al. (2021), Varadi et al. (2022), Velankar et al. (2013).