Precisión estructural real de AlphaFold2 tras corregir el mapeo PDB–UniProt

Benchmark con SIFTS en 10,432 proteínas únicas

José Antonio Tapia Godínez

Maestría en Ciencia de Datos, ITAM

Concurso de Posters de Titulación 2026

Problema y objetivo

Problema

Las comparaciones PDB–AlphaFold2 sin mapeo posicional reportan RMSD mediano de **22.54 Å** (solo 13.9 % bajo 2 Å), sugiriendo fallo masivo del modelo. Esto contradice CASP14 (GDT 92.4/100, equivalente a variabilidad experimental). La discrepancia exige explicación.

Objetivo

Determinar la precisión real de AlphaFold2 con un pipeline reproducible basado en:

- selección diversa por identificador UniProt,
- mapeo SIFTS a nivel residuo,
- superposición Kabsch y RMSD de Cα.

Datos

- 13,000 pares candidatos PDB–AlphaFold2.
- 11,384 pares descargados con ambos archivos.
- **10,432 proteínas únicas** procesadas con SIFTS (91.6 %).

Diseño metodológico

Metodología: SIFTS como puente

```
Pipeline de análisis

1. SIFTS (EBI)
PDB_BEG → SP_BEG
(mapeo de numeración)

2. PDB (RCSB)
estructura experimental

3. AlphaFold2 (EBI)
estructura predicha

4. Kabsch SVD
superposición óptima

5. RMSD por residuo,
aminoácido, grupo
funcional y elemento
```

Decisiones clave

- **PDB** como referencia experimental (>200K estructuras).
- **AF2** (CASP14: GDT 92.4/100, AFDB: >200M proteínas).
- **SIFTS** corrige numeración y selección de cadena.
- **Kabsch** para superposición óptima.

Variables

- **Respuesta:** RMSD de Cα tras alineamiento.
- **Estructurales:** longitud, residuos mapeados.
- **Químicas:** aminoácido, grupo

Hallazgo metodológico central

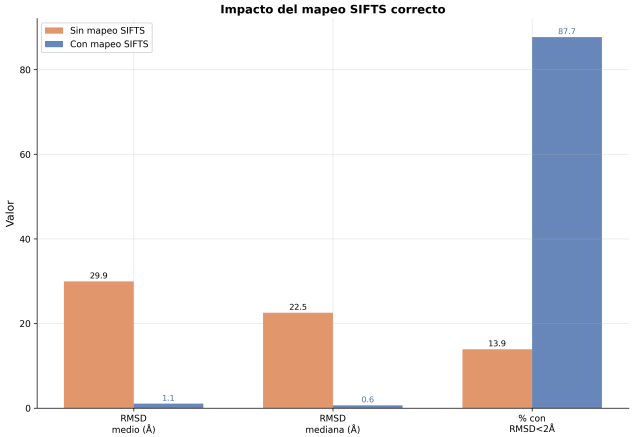

Efecto de usar SIFTS

- RMSD medio: 29.94 Å $\rightarrow$ 1.05 Å
- RMSD mediano: 22.54 Å $\rightarrow$ 0.64 Å
- RMSD $<$ 2 Å: 13.9 % $\rightarrow$ 87.7 %

Interpretación

La mayor parte del error previo provenía de un artefacto de alineación, no de un fallo masivo de AlphaFold2.

Resultados globales

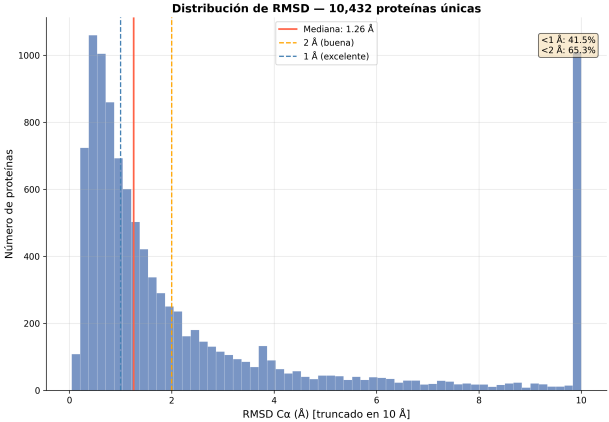

Dataset completo

- 10,432 proteínas únicas
- RMSD mediano: 1.26 Å
- RMSD medio: 3.56 Å
- 41.5 % con RMSD < 1 Å
- 65.3 % con RMSD < 2 Å

Lectura

La mediana representa mejor el desempeño porque la distribución tiene cola derecha y outliers conformacionales.

Tamaño proteico, impacto y conclusiones

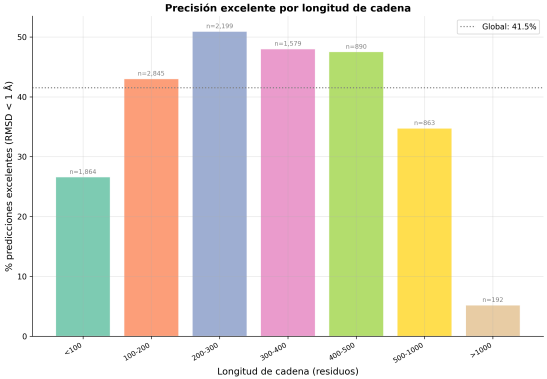

Tamaño proteico

- No aparece un sweet spot universal 250–300.
- 200–300 residuos: mediana 0.98 Å.
- 300–400 residuos: mediana 1.05 Å.
- $>$ 1000 residuos: mediana 4.68 Å.

Conclusiones

- AlphaFold2 = **precisión experimental** en 2/3 del proteoma.
- SIFTS es **requisito**; benchmarks sin él son inválidos.
- El *sweet spot* 250–300 era artefacto, no biología.
- Pipeline transferible a AlphaFold3 y